


Логистическая регрессия

Лазар В. И., Козлова Е. Р.

24 сентября 2025 г.

Бинарная классификация: постановка

Дано: точки (x_i, y_i) , где $y_i \in \{0, 1\}$. Предсказываем вероятность $p(y = 1 | x) \in [0, 1]$, решение по порогу (обычно 0,5).



Почему не подойдёт обычная линейная регрессия?


- Линейная регрессия выдаёт любые числа (\mathbb{R}), а нам нужна вероятность в $[0, 1]$.
- Квадратичная ошибка не «понимает» уверенность: за очень уверенную ошибку штраф почти как за небольшую.
- Хотим модель, у которой $\hat{p} = \Pr(y = 1 \mid x)$, и потери, сильно наказывающие «уверенно неправые» ответы.

Сигмоида: как из \mathbb{R} получить $[0, 1]$

Определение логистической функции (сигмоиды):

$$\sigma(z) = \frac{1}{1 + e^{-z}}, \quad z = \mathbf{w}^\top \mathbf{x} + b.$$

Тогда $\hat{p} = \sigma(z) \in [0, 1]$ — это и есть оценка вероятности класса «1».



Вероятностная модель: Бернулли и правдоподобие

Для одного примера:

$$p(y | x) = \sigma(z)^y (1 - \sigma(z))^{(1-y)}, \quad y \in \{0, 1\}.$$

Для всей выборки (независимость примеров):

$$\mathcal{L}(w, b) = \prod_{i=1}^n \sigma(z_i)^{y_i} (1 - \sigma(z_i))^{(1-y_i)}, \quad z_i = w^\top x_i + b.$$

Учимся максимизируя правдоподобие \mathcal{L} или (эквивалентно) лог-правдоподобие.

Функция потерь логистической регрессии: шаг-за-шагом

1) Логарифмируем произведение (сумма логов):

$$\log \mathcal{L} = \sum_{i=1}^n \left[y_i \log \sigma(z_i) + (1 - y_i) \log(1 - \sigma(z_i)) \right].$$

2) Меняем знак (минимизация вместо максимизации):

$$J(w, b) = -\frac{1}{n} \sum_{i=1}^n \left[y_i \log \sigma(z_i) + (1 - y_i) \log(1 - \sigma(z_i)) \right].$$

Это **кросс-энтропийная** потеря (log loss). Она *сильно* штрафует уверенные ошибки.

Эквивалентные формы log loss

Через $y \in \{0, 1\}$:

$$\ell(y, z) = -y \log \sigma(z) - (1 - y) \log(1 - \sigma(z)).$$


Через $y \in \{-1, +1\}$ и $z = \mathbf{w}^\top \mathbf{x} + b$:

$$\ell(y, z) = \log(1 + e^{-yz}).$$

Эти записи эквивалентны: выберите удобную для анализа/реализации.

Интуиция потерь: как растёт штраф


Для $y = 1$: $\ell = -\log \sigma(z) = \log(1 + e^{-z})$. Для $y = 0$: $\ell = -\log(1 - \sigma(z)) = \log(1 + e^z)$.



Чем больше модель уверена и права (большой по модулю «не тот» знак z), тем больше штраф.

Граница решения и порог

Решаем по порогу $\hat{p} = 0,5$ (то есть $z = 0$) — это **линейная** граница $w^T x + b = 0$.



Чтобы избежать переобучения и сделать веса стабильнее, добавляют штрафы:

$$J_{\text{ridge}} = J + \lambda \|w\|_2^2, \quad J_{\text{lasso}} = J + \lambda \|w\|_1.$$

На практике **стандартизируйте** признаки и подбирайте λ по валидации.